


TensorFlow基础及实现 AI工程师讲座

架构原理 深度学习架构建立






目录



原理架构




深度学习架构建立




Part / 01

原理架构

ARCHITECTURE

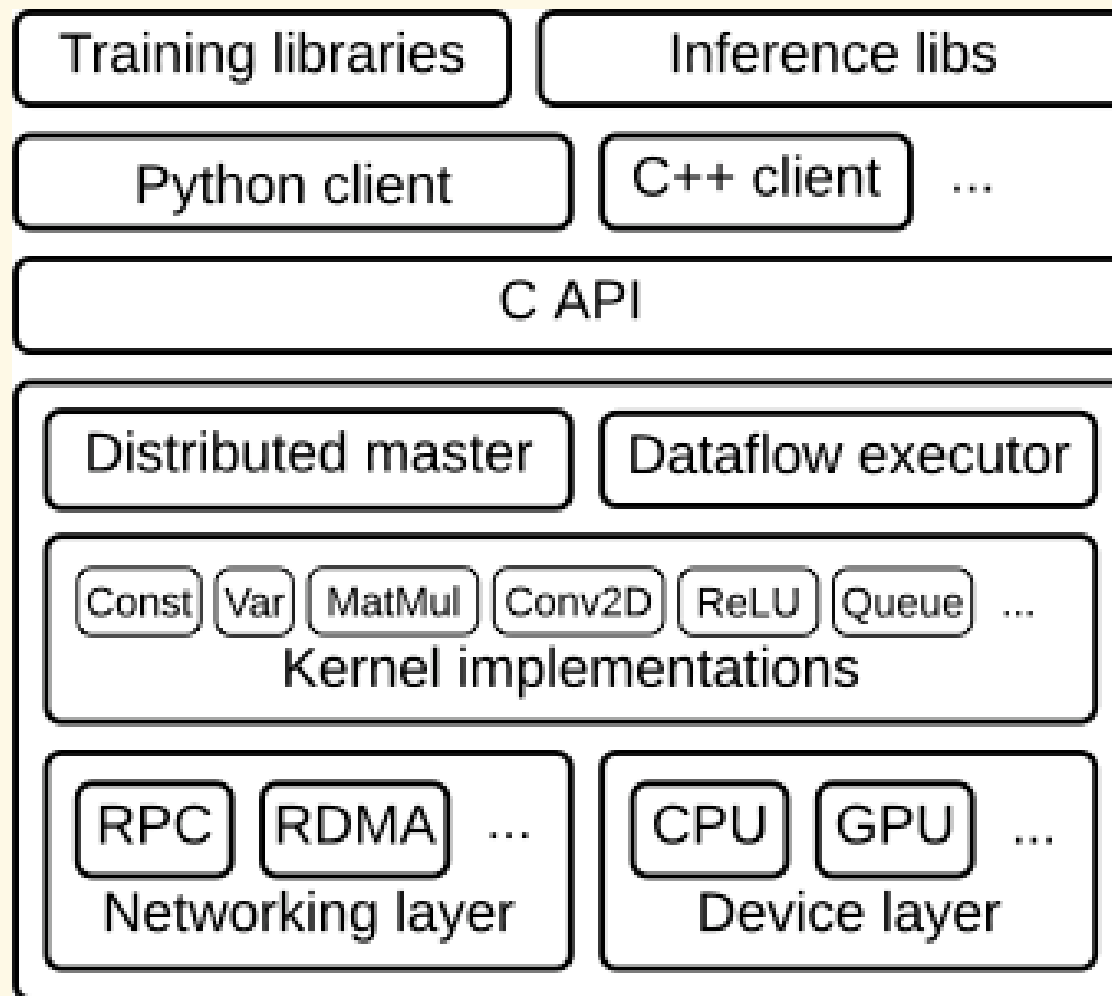





原理架构


ARCHITECTURE

基础架构





计算核心的实现是建立于CPU与GPU之上的，在进行多设备计算的过程中需要考虑二者内存传递速度问题，信息传递用于实现分布式计算，在这之上实现的C API





计算图-单机执行过程抽象








原理架构

ARCHITECTURE

计算图-分布式执行过程抽象



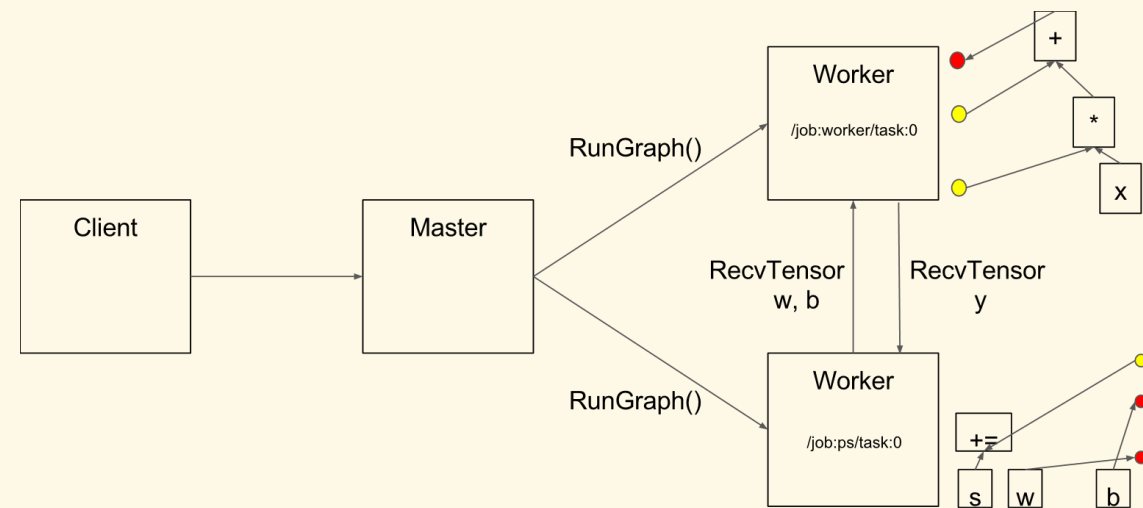
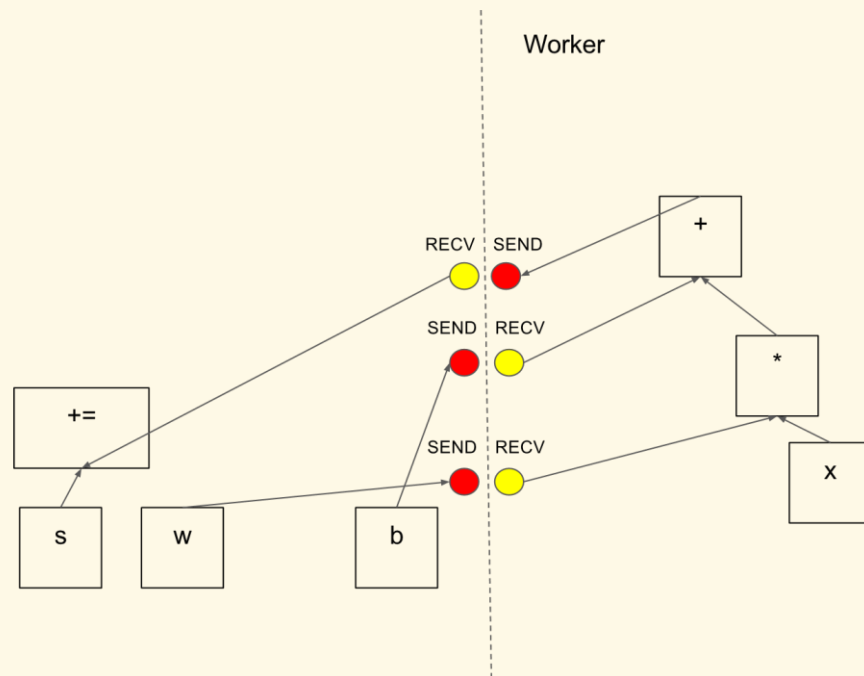


原理架构

ARCHITECTURE


计算图-分布式执行过程抽象

PS



并行化是在迭代计算过程中进行的，需要保证并行粒度足够大。





计算图-分布式执行过程抽象

设置计算任务输出计算设备信息：

```
tf.Session(config=tf.ConfigProto(log_device_placement=True))
```


输出：

MatMul: (MatMul):/job:localhost/replica:0/task:0/cpu:0

b: (Const): /job:localhost/replica:0/task:0/cpu:0


a: (Const): /job:localhost/replica:0/task:0/cpu:0






计算图

所有计算之目的在于获取梯度并更新权值。
回想数学章节的内容，这是整个机器学习
优化过程的核心。
TensorFlow使用了“计算图”的方式去描
述这个过程。



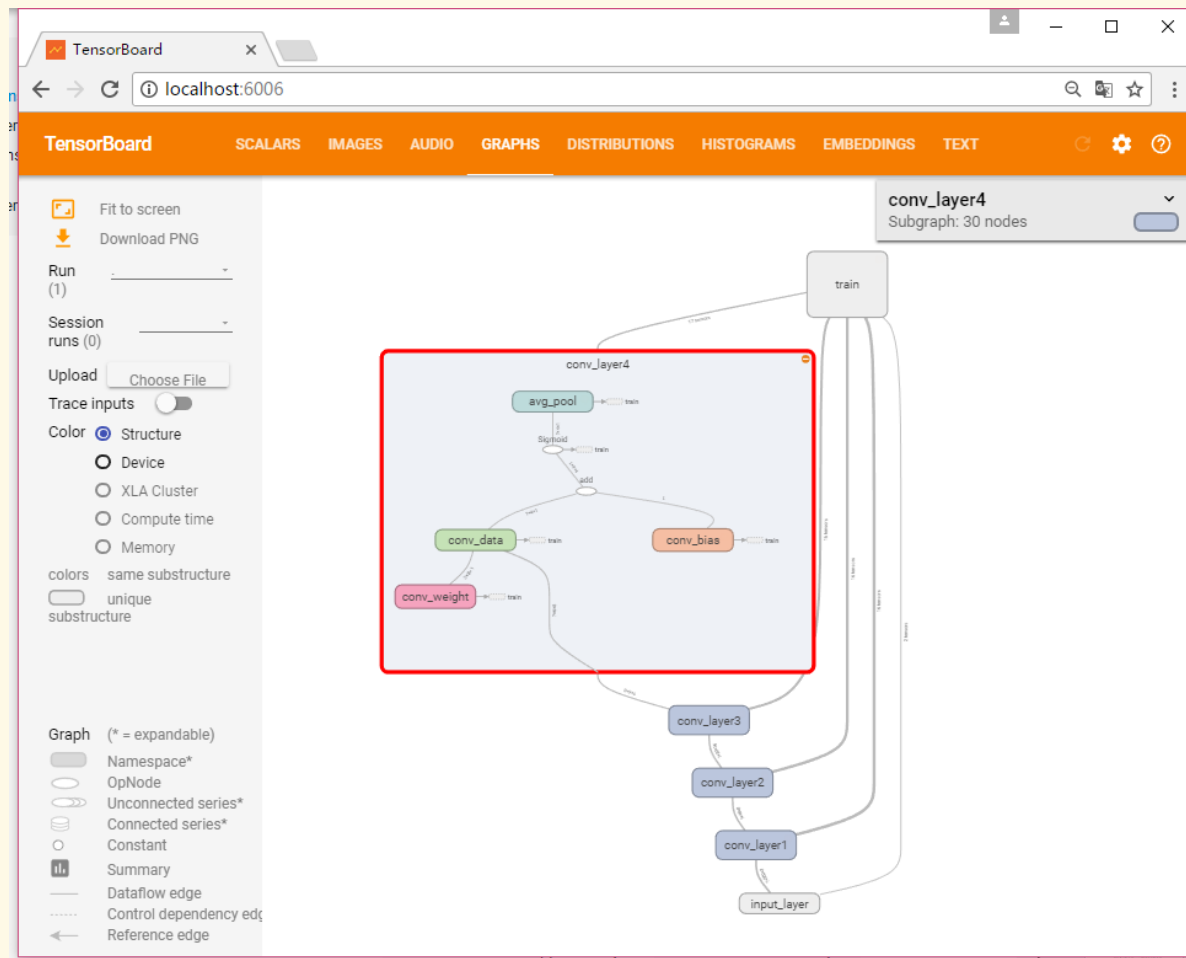



原理架构

ARCHITECTURE

计算图

TensorFlow输出的计算图
(四层卷积)：







Part / 02

深度学习架构的建立

DESIGN






深度学习架构的建立


DESIGN

本节目的在于根据网上给出的深度学习架构能用TensorFlow的PythonAPI自行实现其过程。

本章中默认认为加入如下语句：

```
import tensorflow as tf  
import numpy as np
```





入门

回想：

$$\vec{y} = f(W \cdot \vec{x} + b)$$

$$\varepsilon = (d - y)^2$$

其中输入为 x 输出
为 y ，训练标签为
 d


在机器学习中可训练的量用矩阵表示为
`tf.Variable()`


对于 W 和 b 可以用如下语句:

```
W = tf.Variable(tf.zeros(W_shape))
```

使用初始化后的变量是好的习惯
或者使用

```
W = tf.get_variable( "W" ,[W_shape])
```





入门

更多关于变量

回想：

$$\vec{y} = f(W \cdot \vec{x} + b)$$


$$\varepsilon = (d - y)^2$$


其中输入为x输出
为y，训练标签为
d

上面的`get_variable()`已经展示了变量的域
这对于变量的复用是很重要的概念：

```
with tf.variable_scope("level1"):
    with tf.variable_scope("level2"):
        var = tf.get_variable("var", [3,3])
```

```
with tf.variable_scope("level3"):
    with tf.variable_scope("level4"):
        var = tf.get_variable("var", [3,3])
```





入门

回想：

$$\vec{y} = f(W \cdot \vec{x} + b)$$


$$\varepsilon = (d - y)^2$$


其中输入为 x 输出
为 y ，训练标签为
 d

关于输入 x

对于输入 x ，TensorFlow提供了
placeholder类：

```
x = tf.placeholder(tf.float32,  
shape=batch_size+x_shape)
```





入门

定义函数计算

回想：

$$\vec{y} = f(W \cdot \vec{x} + b)$$

$$\varepsilon = (d - y)^2$$


其中输入为 x 输出
为 y ，训练标签为
 d


W 与 x 是矩阵相乘运算，与 b 是相加运算，
这个运算过程定义如下：

$$\text{matop} = \text{tf.matmul}(x, W) + b$$

函数 f 是激活函数，这里选择激活函数为
sigmoid

$$y = \text{tf.nn.sigmoid}(\text{matop})$$





入门

定义loss

回想：

$$\vec{y} = f(W \cdot \vec{x} + b)$$

$$\varepsilon = (d - y)^2$$


其中输入为x输出
为y，训练标签为
d


利用计算出的y与d进行loss计算：

$$\text{loss} = \text{tf.square}(y-d)$$

这里需要注意的是，x,y,d是训练集的子集，
所以需要进行平均计算(对于简单模型，不
进行平均计算依然能得到结果)

$$\text{loss_mean} = \text{tf.reduce_mean}(\text{loss})$$





入门

回想：

$$\vec{y} = f(W \cdot \vec{x} + b)$$

$$\varepsilon = (d - y)^2$$

其中输入为x输出
为y，训练标签为
d


定义优化算法


```
optimizer = tf.train.GradientDescentOptimizer(0.01)
```

定义迭代过程：

```
step = optimizer.minimize(loss_mean)
```

迭代过程优化的变量为所有Variable()，
除非将其设定为不可训练。





入门

Session

回想：

$$\vec{y} = f(W \cdot \vec{x} + b)$$


$$\varepsilon = (d - y)^2$$


其中输入为 x 输出
为 y ，训练标签为
 d

至此计算过程并未执行，TensorFlow需要
定义Session去执行定义的计算过程。

这里可以定义：

```
sess = tf.Session()
```





入门

变量初始化

回想：

$$\vec{y} = f(W \cdot \vec{x} + b)$$

$$\varepsilon = (d - y)^2$$


其中输入为 x 输出
为 y ，训练标签为
 d


所有变量使用前都需要进行初始化

```
initer = tf.global_variables_initializer()
```

当然需要sess执行

```
sess.run ( initer )
```





入门

训练过程

回想：


$$\vec{y} = f(W \cdot \vec{x} + b)$$


$$\varepsilon = (d - y)^2$$

其中输入为x输出
为y，训练标签为
d

```
for _ in range(step_len):  
    data_d, data_x = get_data_class(batch_len)  
    sess.run(step, feed_dict={x: data_x, d: data_d})
```

训练过程采用feed机制
对于定义的placeholder量。





子结构

CNN


```
tf.nn.conv2d(data, filters, strides, padding)
```

```
tf.nn.pool(data, w_shape, p_type, padding, strides)
```

```
tf.nn.dropout(data, keep_prob)
```

```
tf.nn.l2normalize(data, dim)
```






子结构


RNN

```
tf.contrib.rnn.BasicLSTMCell(lstm_size)
```

```
tf.contrib.rnn.DropoutWrapper()
```



```
tf.contrib.rnn.MultiRNNCell()
```





构建计算图

```
1 def def_struck(net, scale=1.0, activation_fn=tf.nn.relu, scope=None, reuse=None):
2     """Def Struck"""
3     with tf.variable_scope(scope, 'my_def', [net], reuse=reuse):
4         with tf.variable_scope('Branch_0'):
5             tower_conv = slim.conv2d(net, 128, 1, scope='Conv2d_1x1')
6         with tf.variable_scope('Branch_1'):
7             tower_conv1_0 = slim.conv2d(net, 128, 1, scope='Conv2d_0a_1x1')
8             tower_conv1_1 = slim.conv2d(tower_conv1_0, 128, 7,
9                                         scope='Conv2d_0b_1x7')
10            tower_conv1_2 = slim.conv2d(tower_conv1_1, 128, 1,
11                                        scope='Conv2d_0c_7x1')
12            mixed = tf.concat([tower_conv, tower_conv1_2], 2)
13            up = slim.conv2d(mixed, net.get_shape()[2], 1, normalizer_fn=None,
14                            activation_fn=None, scope='Conv2d_1x1')
15            net += scale * up
16            If activation_fn:
17                net = activation_fn(net)
18            return net
```



THANKS
AI工程师讲座

