


人工智能的数学基础

AI工程师讲座

cangye@Hotmail.com

概率论 线性代数和矩阵 数学分析





目录



01


概率论

02

线性代数和矩阵

03


数学分析




Part / 01

概率论

PROBABILITY THEORY








概率论

PROBABILITY THEORY

学习概率论的意义





概率
 $p(x)$

高斯分布

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{x^2}{2\sigma^2}\right)$$

多变量高斯分布


$$p(\vec{x}_m) = \frac{1}{(2\pi)^{\frac{m}{2}} [\det(\underline{\underline{C}})]^{-1/2}} \exp\left(-\frac{1}{2}(\vec{x} - \vec{\mu})^T \underline{\underline{C}}(\vec{x} - \vec{\mu})\right)$$


条件概率
 $p(x|A)$

“不上学的孩子容易成功”

先验概率
 $p(x)$

“我从某渠道得知，印度人做生意80%都不诚实。所以我根据这个概率，选择不和印度人做生意。”







概率概念的应用： 高斯分布下的贝叶斯分类器


首先定义风险(几乎所有的机器学习分析都是从此开始的)：


$$\begin{aligned} \mathcal{R} &= c_{11}p_1 \int_{\mathcal{H}_1} p_x(x|\ell_1) dx + c_{22} p_2 \int_{\mathcal{H}_2} p_x(x|\ell_2) dx \\ &\quad + c_{21}p_1 \int_{\mathcal{H}_2} p_x(x|\ell_1) dx + c_{12} p_2 \int_{\mathcal{H}_1} p_x(x|\ell_2) dx \end{aligned}$$





高斯分布下的贝叶斯分类器等同于线性分类器





补充概念

变量均值


$$\mu = \mathbb{E}(x)$$


总体平均相关系数

$$\mathbb{E}(xx^T)$$

协方差矩阵(类比标量方差)

$$C = \mathbb{E}[(x - \mu)(x - \mu)^T]$$





补充概念


信息熵


$$H(x) = - \sum_{k=-K}^K p_k \log(p_k)$$

与热力学的熵定义相似

$$S = k \ln \Omega$$


衡量系统的混乱程度






信息熵应用

ICA算法







Part / 02

线性代数和矩阵

MATRIX







矩阵和张量


在机器学习中，张量的概念更接近于多维矩阵
而SVD分解等算法主要是针对于矩阵来说

在数学中，张量产生的目的在于表示不受坐标系变换的量，机器学习中的梯度等概念产生于数学中的张量。






张量以及衍生概念




地心说描述的天体运动

左边我们在我们人工智能工作者的眼中称之为过拟合。
四维空间已经可以描述现象，十一维的弦理论依然有存在的意义



日心说描述的天体运动





张量以及衍生概念

Hilbert Space

空间向量内积与二范数

$$x_i g_{ij} x_j = x_i x_i = ||\vec{x}||$$

N维度空间m维
度超曲面

$$f_i(x_1, \dots, x_n) = 0 (i = 1 \dots N - m)$$


为什么说这些？


回忆二维可分过程，一条线分两个类

三维空间中，一个面分两个类

...

N维空间中，N-1维曲面划分两个类







张量以及衍生概念

梯度与Hessian矩阵

在讨论梯度的时候我们本能的将其放在三维空间中想象，也就是说他是有“长度”的，所以是属于张量的概念。下图二维空间拉伸





张量以及衍生概念

梯度与Hessian矩阵


$f(\vec{x})$ 函数展开：


$$f(\vec{x}_0) + \nabla f(\vec{x}) \Big|_{x=x_0} \cdot d\vec{x} + d\vec{x} \underline{\underline{H}} \Big|_{x=x_0} d\vec{x}$$

梯度： $\nabla f(\vec{x})$

Hessian矩阵： $\underline{\underline{H}}$




在将梯度写为 $\nabla f(\vec{x}) = \frac{\partial f}{\partial x_i}$ 的时候
已经默认这是欧式空间中的梯度






张量以及衍生概念应用

回想前面说过的十一维
弦理论存在的意义
抑或问题






张量以及衍生概念应用


泛函

通常来讲我们会用一个数代表整个系统状态，而这个数字取最小(最大)值时系统进入稳定状态。则称系统为泛函。优化过程称之为凸优化。或者更直白一点，系统就是函数，泛函是函数的函数。

例子：

从家到公司走路需要消耗能量，如何找到一条能量最少的路。





矩阵的概念

矩阵的秩(rank)

线性独立的量的最小个数

矩阵的维
(dimension)

与空间中概念类似

矩阵的迹(trace)

对角线元素之和


矩阵示例

放射变换

$$z = Ax + b$$

z, x 为坐标， A 为矩阵，这里矩阵的概念与张量无关







Part / 03

数学分析实例


ANALYSIS






**本节列举一些简单的分析实例
用以加深数学原理的理解**





贝叶斯分类器详述






风险函数：

$$\begin{aligned} \mathcal{R} &= c_{22}p_2 + c_{21}p_1 \\ &+ \int_{\mathcal{H}_1} [p_2(c_{12} - c_{22})p_x(x|\ell_2) - p_1(c_{21} - c_{11})p_x(x|\ell_1)] dx \end{aligned}$$






最终化为比较Lambda大小

$$\Lambda = \frac{p_x(x|\ell_2)}{p_x(x|\ell_1)}$$

回忆：


$$p(\vec{x}_m) = \frac{1}{(2\pi)^{\frac{m}{2}}} \left[\det(\underline{\underline{C}}) \right]^{-1/2} \exp\left(-\frac{1}{2}(\vec{x} - \vec{\mu})^T \underline{\underline{C}}(\vec{x} - \vec{\mu})\right)$$






最终化为


$$\log(\Lambda) = C^{-1}(\mu_1 - \mu_2)x + b$$






最小均方算法






风险函数：

$$\mathcal{R} = (d - f(x))^2$$







风险函数：

$$\mathcal{R} = (d - f(x))^2$$

\mathcal{R} 是关于 x 的凸函数，同时也是关于函数 $f(x)$ 的泛函
这是泛函分析过程，构建凸函数是几乎所有有监督学习的起点。







定义函数为

$$f(x) = Ax + b$$

所有的泛函数值求解过程都需要定义试函数，这通常是在无解析解的情况下所做的简化，现函数变为关于A的函数：



$$\mathcal{R}(A, b)$$





$\mathcal{R}(A, b)$ 最小值：

迭代过程：
$$x(n+1) = x(n) + \nabla_{A,b} \mathcal{R}$$



THANKS
AI工程师讲座

